Spark SQL

陈超 @CrazyJvm



跟Shark的关系?

- Shark已经不会再投入资源去更新了
- Spark SQL利用了Shark中最好的部分(如列式存储)

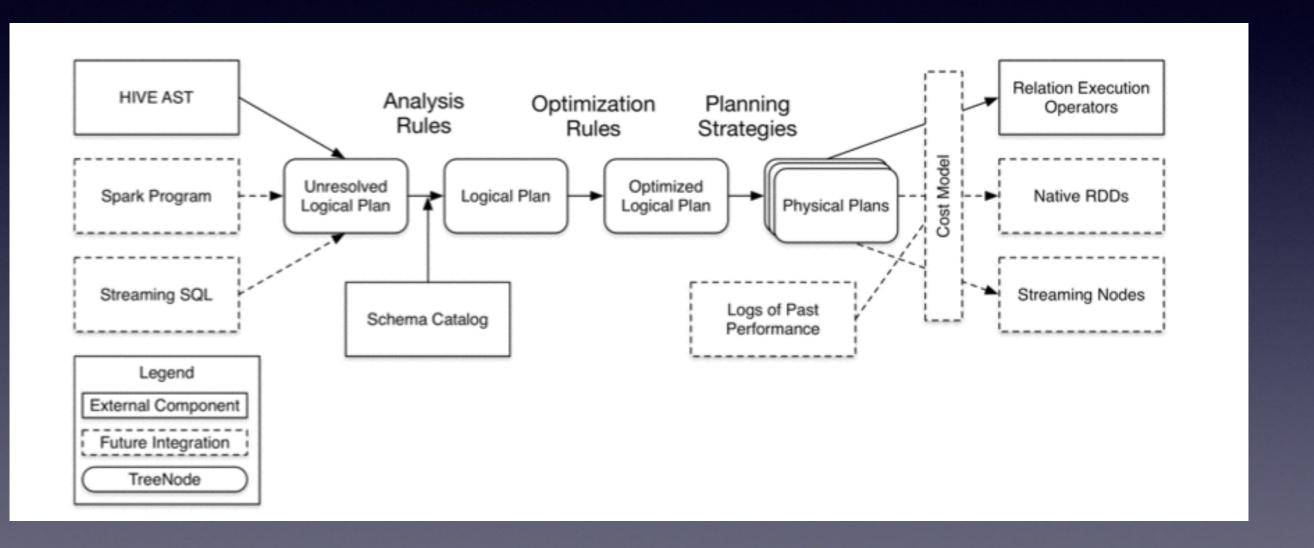


与Hive的兼容性

- 支持使用hql来写查询语句
- 兼容metastore
- 使用Hive的SerDes
- 对UDFs, UDAFs, UDTFs作了封装



架构





Tree Transformations

• 很多概念都可以表示成树:

Logical Plans, Expressions, Physical Operators

- trees的不同阶段的transformation都是为了 execution做准备
- 把各个阶段解耦使得更易扩展



• 接下来介绍核心接口与操作



- org.apache.spark.sql.SQLContext
- 所有SQL操作的入口

val sc: SparkContext

val sqlContext = new org.apache.spark.sql.SQLContext(sc)

import sqlContext._ //导入各种sql操作的入口与各种隐式转换



- SchemaRDD
- Schema + RDD
- 可以register为一个table =



RDD变成relation。

- 定义case class =
- 加载数据后变成case class对象的RDD
- 将RDD注册成为table



Parquet支持

- 支持读取Parquet中的数据
- 支持写到Parquet中时保存元数据的schema信息
- 列式存储避免读出不需要的数据



Parquet步骤

- xxx.saveAsParquetFile("xxx.parquet") //存
- val parquetFile = sqlContext.parquetFile("xxx.parquet") //读
- parquetFile.registerAsTable("parquetFile") //跟之前完全一样



json支持

- sqlContext.jsonFile
- 支持嵌套查询 where a.b.c='xxx'



DSL

用Scala的symbols代表table中的每一列



cached tables

- cacheTable("tableName")
- · 列式存储(压缩+减少内存使用+减少GC)
- uncacheTable("tableName")取消缓存
- 调用原生rdd的cache接口无法享受列式存储的优势



Hive操作

- val hiveContext = new org.apache.spark.sql.hive.HiveContext(sc)
- SBT : SPARK_HIVE=true sbt/sbt assembly/assembly
 JDCB : sbt/sbt -Phive-thriftserver assembly/assembly
- MAVEN: -Phive 假如要JDBC功能, 还需 -Phive-thriftserver



ClassPath的问题

- CLASSPATH="\$SPARK_CLASSPATH:\$SPARK_SUBMIT_CLASSPATH: \$FWDIR/conf"
- metastore所用数据库的驱动程序的jar包



用hql查询

- val hiveContext = new
- hiveContext.hql("...")



UDF

- ./spark-shell --jars /data/program/udf.jar
- 进shell后再add jar
- 最新支持registerFunction方式(trait UDFRegistration)



Thrift JDBC Server

- 基于Hive0.12的HiveServer2
- 可用beeline测试(Spark与Hive0.12带的均可)



启动与配置

- ./sbin/start-thriftserver.sh
- 环境变量HIVE_SERVER2_THRIFT_PORT与HIVE_SERVER2_THRIFT_BIND_HOST
- 配置文件hive.server2.thrift.port与hive.server2.thrift.bind.host



beeline测试

./beeline -u jdbc:hive2://server1:10000/default -n cc



• JDBC代码访问Thrift JDBC Server



• 目前,一切说Shark可以无缝迁移到Spark SQL的话都是扯淡!

• Spark SQL在飞速的发展和完善中



谢谢大家

微博: @CrazyJvm

微信公众账号: ChinaScala

